

UNIVERSITÀ DEGLI STUDI DI MILANO FACOLTÀ DI SCIENZE E TECNOLOGIE

Corso di Laurea in Informatica Musicale

SISTEMA DI RACCOMANDAZIONE BASATO SU COLLABORATIVE FILTER PER PIATTAFORMA MOON CLOUD FACENTE PARTE DELL'AMBITO DELLA SECURITY ASSURANCE

Relatore: Claudio Agostino Ardagna Correlatore: Valerio Bellandi

> Tesi di Laurea di: Andrea Michele Albonico Matricola: 886667

Anno Accademico 2018/2019

Ringraziamenti

 $Andrea\ Michele\ Albonico$

Prefazione

I sistemi di raccomandazione (*Recommendation System*) hanno avuto un forte sviluppo negli ultimi decenni e nascono proprio con lo scopo di identificare quegli oggetti (detti generalmente *item*) all'interno di un vasto mondo di informazioni che possono essere di nostro interesse e tanto maggiore è il grado di conoscenza dell'individuo e tanto più vengono ritenuti affidabili.

Il motivo di questo successo risiede nella riuscita integrazione di tali sistemi in applicazioni commerciali, soprattutto nel mondo dell'E-commerce e nel fatto che sono in grado di aiutare un utente a prendere una decisione, che sia la scelta di un film per l'uscita con gli amici il sabato sera, di una playlist da ascoltare durante un viaggio in auto o in un momento di lettura, e via discorrendo.

Moon Cloud è una piattaforma erogata come servizio che fornisce un meccanismo di Security Governance centralizzato. Garantisce il controllo della sicurezza informatica in modo semplice e intuitivo, attraverso attività di test e monitoraggio periodiche e programmate (Security Assurance). L'obbiettivo di questa tesi è stato quello di aggiungere, al già presente sistema per la scelta dei controlli all'interno delle attività di test, un sistema di raccomandazione che possa consigliare all'utente delle possibili Evaluation rispetto al target indicato; in questo modo anche l'utente meno esperto può usufruire dei servizi offerti da Moon Cloud in modo semplice e intuitivo.

La tesi è organizzata come segue:

- Capitolo 1 Introduzione a Moon Cloud in questo capitolo viene descritta la piattaforma Moon Cloud e il suo funzionamento in ambito di Security Assurance.
- Capitolo 2 Tecnologie utilizzate in questo capitolo vengono presentati gli studi e le analisi di soluzioni esistenti, studi delle tecnologie utilizzate per la realizzazione del progetto.
- Capitolo 3 Collaborative filtering in questo capitolo viene descritto in modo più approfondito gli studi compiuti sui Filtri Collaborativi

vi PREFAZIONE

che hanno portato alla realizzazione dei sistemi di raccomandaizone proposti nella soluzione implementata per la piattaforma Moon Cloud, inoltre verrano mostrate le relative porzioni di codice.

- Capitolo 4 Descrizione della soluzione in questo capitolo viene descritta in maniera dettagliata la realizzazione dell'applicativo, analizzando quali sono state le difficoltà maggiori, i risultati ottenuti e l'uso che se ne è fatto.
- Capitolo 5 Conclusioni in questo capitolo vengono esposte le conclusioni e i possibili sviluppi futuri delle attività svolte e del sistema realizzato.

Indice

Pr	efaz	ione			\mathbf{v}		
1	Intr	oduzio	one a Moon Cloud		1		
	1.1	Moon	n Cloud overview		1		
	1.2		esso di Evaluation				
2	Tecnologie utilizzate						
	2.1	Perch	né Python e Django		7		
	2.2	Docke	er		11		
	2.3	Strutt	ture dati gerarchiche		12		
		2.3.1					
		2.3.2	The Nested Set Model		14		
	2.4	Sisten	mi di raccomandazione		17		
		2.4.1	Content-based filtering		19		
		2.4.2	Collaborative filtering		19		
		2.4.3					
3	Collaborative filtering 23						
	3.1		arg ory-based		23		
			User-based filtering				
		3.1.2	9				
		3.1.3					
4	Des	crizion	ne della soluzione		33		
5	Cor	clusio	oni		43		
\mathbf{Bi}	bliog	grafia			45		

Elenco delle figure

1.1	Security Compliance Evaluation	4
2.1	Schema generico di funzionamento di un applicativo web svi-	
	luppato con Django	10
2.2	Schematizzazione del contenuto di un Container in Docker	11
2.3	Esempio della rappresentazione gerarchica parziale dei dati nel	
	progetto in questione	13
2.4	Esempio della gestione di dati in modo gerarchico secondo	
	il Nested Set Model, utilizzando dati presi dal database del	
	progetto in questione	14
2.5	Esempio della gestione di dati in modo gerarchico secondo	
	il Nested Set Model, utilizzando dati presi dal database del	1.0
0.6	progetto in questione	16
2.6	Categorizzazione generale dei sistemi di raccomandazione	17
3.1	Esempio di applicazione di un sistema di raccomandazione	
	User-based	24
3.2	Esempio di applicazione di un sistema di raccomandazione IB-	
	CF	27
4.1	Struttura del database	36
4.2	Home page	37
4.3	Home page per la navigazione della tassonomia	38
4.4	Dettagli della tassonomia sottoforma di tabella come nella	
	base di dati	38
4.5	Risultato dell'operazione selezionata sul nodo in questione	38
4.6	Admin page	41
4.7	Esempio di Admin page per le Evaluation	42
4.8	Esempio di Admin page per il caso in cui si vuole aggiungere	
	una nuova Evaluation	42

Elenco delle tabelle

2.1	Esempio di una possibile tabella per gestire dati in modo	
	gerarchico secondo l'Adjacency List Model	14
2.2	Esempio di una tabella per gestire dati in modo gerarchico	
	secondo il Nested Set Model	15

Capitolo 1

Introduzione a Moon Cloud

In questo capitolo verrà descritto in modo più approfondito il funzionamento della piattaforma Moon Cloud e unitamente al motivo dell'implementazione della soluzione proposta.

1.1 Moon Cloud overview

La diffusione di sistemi Information and Communications Technology (acronimo ICT) ha avuto luogo nella maggiorparte degli ambienti lavorativi e privati in termini di servizi offerti, automazione di processi e incremento delle performance. L'uso di questa tecnologia ha assunto importanza a partire dagli anni novanta come effetto del boom di Internet e al giorno d'oggi le professionalità legate al mondo dell'ICT crescono in numero e si evolvono per specificità, per operare in ambienti fortemente eterogenei ma sempre più interconnessi fra di loro come il Cloud Computing, i Social Newtwork, il Marketing Digitale, i Sistemi IoT, la Realtà Virtuale, etc.

Il Cloud Computing ha portato un rivoluzionario paradigma nella creazione di un nuovo business virtuale accessibile in qualunque momento e in qualunque luogo; esso sfrutta le tecnologie messe a disposizione dai sistemi ICT come le operazioni di virtualized computing, internet e distributed computing, provvedendo un sistema integrato molto potente. Google, Microsoft, Amazon sono un esempio di aziende che forniscono servizi di Cloud Computing in business ICT. Si può definire il Cloud Computing come l'abilità di accedere a risorse (come database o applicazioni) in tutto il mondo attraverso una rete in poco tempo.

Gli immensi benefici del Cloud in termini di flessibilità, consumo delle risorse e gestione semplificata, la rende la prima scelta per utenti e industrie per il deploy dei loro sistemi IT. Tuttavia il Cloud Computing solleva diverse

problematiche legate alla mancanza di fiducia e trasparenza dove i clienti necessitano di avere delle garanzie sui servizi Cloud ai quali si affidano; spesso i fornitori di questi servizi non fornisco ai clienti le specifiche riguardanti le misure di sicurezza messe in atto.

Negli ultimi anni, sono state sviluppate tecniche e modi per rendere sicuri questi sistemi e proteggere i dati degli utenti, portando alla diffusione di approcci eterogenei che incrementaro la confusione negli utenti. Tecniche tradizionali di verifica della sicurezza basati su metodi di analisi statistica non sono più sufficenti e devono essere integrati con processi di raccolta di prove (in inglese evidence) da sistemi Cloud in produzione e funzionanti. In generale il Cloud Security definisce i modi, come criptazione e controllo degli accessi, per proteggere attivamente gli asset da minaccie interne ed esterne, e fornire un ambiente in cui i clienti possano affidarsi e interagire in totale sicurezza. Tutto questo non basta a rendere il Cloud degno di fiducia e trasparente, per questo sono state introdotte tecniche di Security Assurance, delle garanzie che permettono di ottenere la fiducia necessaria nelle infrastrutture e/o nelle applicazioni di dimostrare il rispetto di certe proprietà di sicurezza, e che operino normalmente anche se subiscono attacchi; grazie alla raccolta e allo studio di evidence è possibile che venga accertata la validità e l'efficenza delle proprietà di sicurezza messe in atto.

Il prezzo che si paga per i benefici di questa tecnologia è dato dall'incremento di violazioni di sicurezza, che oggigiorno preoccupa tutte le aziende e di conseguenza anche i loro clienti, con l'incremento del rischio di fallimento per i servizi più importanti dovuti a violazioni della privacy e al furto di dati.

Il mercato sta lentamente notando che non è l'inadequamento tecnologico dei sistemi di sicurezza che incrementa il rischio delle violazioni di sicurezza; piuttosto, la mal configurazione e l'errata integrazione di questi sistemi nei processi di business [2]. L'utilizzo di sistemi di sicurezza e di controllo migliori non garantisce in modo assoluto la sicurezza dell'infrastruttura; per garantire ciò è necessario implementare un processo continuo di diagnostica e verifica della corretta configurazione dei controlli, supervisionando il loro comportamento, accertandosi che sia quello aspettato.

Il Security Assessment diventa allora un aspetto importante specialmente negli ambienti Cloud e IoT. Questo proccesso, costituito da un insieme di attività mirate alla valutazione del rischio in sistemi IT, deve essere portato avanti in modo continuo e olistico, per correlare le evidence raccolte da sempre maggiori meccanismi di protezione [1].

Moon Cloud è una soluzione PaaS (acronimo inglese di Platform as a Service) che fornice una piattaforma B2B (Business To Business) innovativa per verifiche, diagnostiche e monitoraggio dell'adeguatezza dei sistemi ICT rispetto alle politiche di sicurezza, in modo continuo e su larga scala. Moon Cloud

supporta una semplice ed efficente *ICT Security Governance*, dove le politiche di sicurezza possono essere definite dalle compagnie stesse (a partire da un semplice controllo sulle vulnerabilità a linee guida di sicurezza interna), da entità esterne, imposte da standard oppure da regolamentazioni nazionali o internazionali.

La sicurezza di un sistema o di un insieme di asset dipende solo parzialmente dalla forza dei singoli meccanismi di protezione isolati l'uno dall'altro; infatti, dipende anche dall'abilità di questi meccanismi di lavorare continuamente in sinergia per provvedere una protezione olistica. In più, quando i sistemi Cloud e i servizi IoT sono coinvolti, le dinamiche di questi servizi e la loro rapida evoluzione rende il controllo dei processi all'interno dell'azienda e le politiche di sicurezza più complesse e prone ad errori.

I requisiti ad alto livello fondamentali per poter garantire le Security Assurance sono:

sistema olistico è richiesta una visione globale e pulita dello status dei sistemi di sicurezza; inoltre è cruciale distribuire lo sforzo degli specialisti in sicurezza per migliorare il processo e le politiche messe in atto. Si parte da delle valutazioni fatte manualmente a quella semi-automatiche che vengono usate per ispezionare i meccanismi di sicurezza.

monitoraggio continuo ed efficiente è necessario un controllo continuo che valuti l'efficenza dei sistemi di sicurezza per ridurre l'impatto dell'errore umano, soprattutto dal punto di vista organizzativo. La coesistenza di componenenti in conflitto o la mancata configurazione dovuta al cambiamento dell'ambiente possono essere scenari che richiedono un monitoraggio e un aggiornamento continuo.

singolo punto di management avere un solo punto d'accesso in cui poter gestire tutti gli aspetti relativi alla sicurezza, permette di avere sotto controllo le politiche di sicurezza. Inoltre disporre di un inventario degli asset da proteggere permette di poter conoscere quali meccanismi di protezioni applicare.

reazioni rapide a incidenti di sicurezza spesso la reazione ad incidenti di sicurezza è ritardata da due fattori: il tempo richiesto per rilevare l'incidente e il tempo per analizzare il motivo dell'accaduto; e avere un sistema che implementa un monitoraggio continuo permette di venire a conoscenza di questi problemi in breve tempo e agire di conseguenza.

Moon Cloud è basato su una tecnica di Security Assurance garantendo che

tutte le attività aziendali si compiano seguendo i requisiti prestabiliti da appropriate politiche e procedure precedentemente definite.

Viene definita una Security Compliance Evaluation, un processo di verifica a cui un target viene sottoposto e il cui risultato deve soddisfare i requisiti richiesti da standard e politiche. A partire da questi processi di controllo, che devono a loro volta essere affidabili, si ottendo delle evidence; queste ultime possono essere raccolte monitorando l'attività del target oppure, come già menzionato, sottoponendo il target a scenari critici o di testing. In particolare, una Security Compliance Evaluation è un processo di verifica dell'uniformità di un certo target a una o più politiche attraverso una serie di controlli che a seconda del valore booleano (successo pari a 1 o insuccesso pari a 0) associato ad ogni controllo viene prodotto un valore booleano per le politiche; se un target supera tutti i controlli, quindi tutti i valori booleani associati ad ogni controllo è pari al successo, a cui è sottoposto allora significa che rispetta la politica scelta.

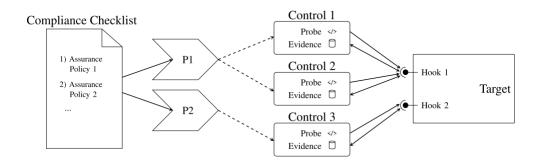


Figura 1.1: Security Compliance Evaluation

1.2 Processo di Evaluation

Moon Cloud implementa il processo di Security Compliance Evaluation in Figura 1.1 usando controlli di monitoraggio o di test personalizzabili. Inoltre garantisce, oltre a tutti i requisisti ad alto livello elencati precedentemente 1.1, anche i seguenti:

Moon Cloud è una piattaforma Cloud centralizzata presentando una visione olistica dello stato di sicurezza di un dato sistema.

Moon Cloud implementa un sistema di Security Assurance Evidence-based continuo, implementato come processo di Compliance, basato su politiche custom o standard.

Moon Cloud è offerto come un servizio (PaaS), dove le attività di Evaluation possono essere facilmente ed efficentemente configurate su un target asset, senza l'intervento dell'uomo.

Moon Cloud permette di schedulare delle ispezioni automatiche, grazie all'inventario di asset protetto.

Moon Cloud Evaluation Engine può ispezionare dall'interno un sistema, gestendo così delle minaccie interne; permettendo anche reazioni rapide a incidenti di sicurezza e veloci rimedi, grazie alla raccolta continua di evidence.

In generale, l'architettura di Moon Cloud è costituita da un'Assurance Manager che gestisce i processi di Evaluation attraverso un set di Execution Cluster; ognuno dei quali gestisce ed esegue un set di probe che collezionano le evidence necessarie per effettuare i processi di valutazione. Tutte le attività di collezione sono eseguite dal probe, ognuno dei quali è uno script Python fornito come una singola immagine di Docker, che viene inizializzata quando viene triggerata una Evaluation ed è distrutta quando il processo di Evaluation è terminato.

Accedendo alla piattaforma di Moon Cloud, l'utente può definire le proprie politiche di sicurezza e attività di Evaluation come espressioni booleane di controlli di sicurezza e altre politiche predefinite. Una volta che una politica viene definita, l'utente può decidere quando schedulare l'Evaluation; e nel momento in cui un processo di Evaluation viene inizializzato, tutti i controlli vengono eseguiti e i risultati dell'espressioni booleane vengono memorizzati e restituiti all'utente. A questo punto l'utente può accedere a questi risultati a diversi gradi di precisione: una visione sommaria e generale di tutte le politche implentate e dello stato generale del sistema di sicurezza, al risultato di una specifica politica oppure alle evidence raccolte per una Evaluation. Per poter rendere ancora più intuituivo e semplice da utilizzare un sistema di questa importanza, si è pensato di introdurre un sistema che possa raccomandare agli utenti, in base agli asset che vuole proteggere e monitorare, una serie di Evaluation o politihe da applicare in quei casi; questo permette

anche a utenti meno esperti di poter configurare in modo rapido ed efficente

dei meccanismi di protezione da minaccie.

Capitolo 2

Tecnologie utilizzate

In questo capitolo verranno descritte le attività preliminari per la realizzazione di questo progetto, le tecnologie utilizzate unitamente alle motivazioni legate all'uso di questi sistemi rispetto ad altri. In particolare nel capitolo successivo verranno approfonditi a livello pratico i sitemi di raccomandazione Memory-based i quali sono stati utilizzati per l'implementazione della soluzione.

2.1 Perché Python e Django

Python Python è un linguaggio di programmazione ad alto livello, orientato agli oggetti, adatto, tra gli altri usi, a sviluppare applicazioni distribuite, scripting, computazione numerica e system testing; ideato e rilasciato pubblicamente per la prima volta nel 1991 dal suo creatore Guido van Rossum, programmatore olandese.

Python supporta diversi paradigmi di programmazione, come quello objectoriented (con supporto all'ereditarietà multipla), quello imperativo e quello funzionale, ed offre una tipizzazione dinamica forte. È fornito di una libreria built-in estremamente ricca, che unitamente alla gestione automatica della memoria e a robusti costrutti per la gestione delle eccezioni fa di Python uno dei linguaggi più ricchi e comodi da usare.

Inoltre è anche semplice da usare e imparare. Python, nelle intenzioni di Guido van Rossum, è nato per essere un linguaggio immediatamente intuibile. La sua sintassi è pulita e snella così come i suoi costrutti, decisamente chiari e non ambigui. I blocchi logici vengono costruiti semplicemente allineando le righe allo stesso modo, incrementando la leggibilità e l'uniformità del codice anche se vi lavorano diversi autori.

Un aspetto inusuale del Python è il metodo che usa per delimitare i blocchi di programma, che lo rende unico fra i linguaggi più diffusi.

```
# Testing if two strings are equals

def test(got, expected):
    if got == expected:
        prefix = ' OK '
    else:
        prefix = ' X '
        print('%s got: %s expected: %s' % (prefix, repr(got), repr(expected)))

def main():
    print('verbing')

test('hail', 'hailing')

test('hail', 'hailing')

test('swiming', 'swimingly')

test('do', 'do')

if __name__ == '__main__':
    main()
```

Listing 2.1: Esempio di programma scritto in Python

Nei linguaggi derivati dall'ALGOL come Pascal, C e Perl, i blocchi di codice sono indicati con le parentesi oppure con parole chiave (il C ed il Perl usano ; il Pascal usa begin ed end). In questi linguaggi è solo una convenzione degli sviluppatori il fatto di indentare il codice interno ad un blocco, per metterlo in evidenza rispetto al codice circostante. In Python invece di usare parentesi o parole chiave, usa l'indentazione stessa per indicare i blocchi nidificati in congiunzione col carattere "due punti" (:). Si può usare sia una tabulazione, sia un numero arbitrario di spazi, ma lo standard Python è di 4 spazi.

Python è un linguaggio pseudocompilato: un interprete si occupa di analizzare il codice sorgente (semplici file testuali con estensione .py) e, se sintatticamente corretto, di eseguirlo e non esiste una fase di compilazione separata (come avviene in C, per esempio) che generi un file eseguibile partendo dal sorgente [7].

Django Django è un web framework di alto livello basato su Pyhton che permette di sviluppare rapitamente e con tutti i presupposti per un sistema sicuro, un sito web perfettamente mantenibile, Django si occupa della maggiori grane del sviluppo web, così da permetterti di concentrarti sulla scrittura della tua app; inoltre è open-source e ha una comunità attiva, una documentazione completa e sempice da consultare.

Django aiuta a scrivere software con le seguenti caratteristiche [3]:

Versatile: è usato per la creazione di praticamente tutti i tipi di siti web, a partire a sistemi per la gestioni di contenuti e wiki, social network e siti di notizie; può lavorare con qualunque client-side framework, gestire contenuti in quasi tutti i formati (inclusi HTML, RSS feeds, JSON, XML, etc). Internamente permette la scelta e l'implementazione di qualsiasi funzionalità (es. molti dei database più popolari, etc.).

Sicuro: aiuta gli sviluppatori a evitare gli errori più comuni in merito alla sicurezza provvedendo un framework costruito per eseguire le operazioni in modo corretto e sicuro. Ad esempio, Django fornisce un modo sicuro per gestire gli account degli utenti e le relative password, evitando errori comuni come inserire informazioni riguardanti la sessione dell'utente nei cookies dove sarebbero vulnerabili (invece i cookie contengono soltanto una chiave, e i valori effettivi sono salvati nel database) o salvare direttamente una password invece di una hash password.

Mantenibile: il codice di Django è scritto seguedo i principi e i pattern che incoraggiano la creazione di codice mantenibile e riusabile. Inoltre particolare, fa uso del principio "Don't Repeat Yourself" (DRY) così da ridurre al minimo le duplicazioni non necessarie, diminuendo la quantità di codice. Django raggruppa parti di codice legto in moduli seguendo le linee guida del pattern Model View Controller (MVC).

Portatile: Django essendo scritto in Python, un linguaggio multi piattaforma, lo rende indipendente dal sistema operativo eseguito sul server,
che sia Linux, Windows o Mac OS X. Per di più, Django è ben supportato da molti web hosting provider, che spesso provvedono a specifche
infrastructure e e documentazione per l'hosting di siti web in Django.

Un tradizionale sito web attende delle richieste HTTP dal browser web (o altri client). Quando viene ricevuta una richiesta, di tipo POST o GET, l'applicazione legge le informazioni contenute nel URL e altri possibili dati a seconda del tipo di richiesta. A seconda della richiesta è possibile che vengano letti o scritti dati da un database o altre operazioni che portino al soddisfacimento della richiesta. A quel punto l'applicazione ritorna una risposta al browser web, spesso in modo dinamico, creando una pagina HTML da mostrare in cui è possibile inserire o recuperare dati in placeholder in un template HTML.



Figura 2.1: Schema generico di funzionamento di un applicativo web sviluppato con Django

Un'applicazione web in Django tipicamente raggruppa il codice che gestisce questi diversi passaggi in file separati [5]:

URL: mentre è possibile processare richieste da qualsiasi URL attraverso unas singola funzione, è più mantenibile scrivere diverse funzioni chiamate View per gestire ogni risorsa. un URL mapper è usato per reindirizzare le richieste HTTP alla view corretta in base all'URL della richiesta; inoltre è possibile controllare se nell'URL è presente un particolare pattern di stringhe o numeri, e passare di conseguenza la richiesta alla funzione appropriata come dati da elaborare.

View: una View è una funzione che gestisce le richieste HTTP, e restituisce una risposta HTTP. Le view accedono ai dati necessari per soddisfare la richiesta attraverso i Model, e delegano la formattazione delle risposte ai template.

Model: i Model sono oggetti in Python che definiscono la struttura dei dati dell'applicazione, e provvedono meccanisci per gestirla (add, modify, delete) e query per interpellare il database.

2.2. DOCKER 11

Template: un template è un file di testo che definisce la struttura o il layout di un file (come una pagina HTML), attraverso placeholder per rappresentare il contenuto effettivo. Una View può creare dinamicamente una pagina HTML usando un template HTML, popolandolo con dati presi dal Model.

2.2 Docker

Docker è una piattaforma software che permette di creare, testare e distribuire applicazioni con la massima rapidità. Docker raccoglie il software in unità standardizzate chiamate container che offrono tutto il necessario per la loro corretta esecuzione, incluse librerie, strumenti di sistema, codice e runtime. Con Docker, è possibile distribuire e ricalibrare le risorse per un'applicazione in qualsiasi ambiente, tenendo sempre sotto controllo il codice eseguito. La tecnologia Docker utilizza solitamente il kernel di Linux e le sue funzionalità, come Cgroups e namespace, per isolare i processi in modo da poterli eseguire in maniera indipendente. Questa indipendenza è l'obiettivo dei container: la capacità di eseguire più processi e applicazioni in modo separato per sfruttare al meglio l'infrastruttura esistente pur conservando il livello di sicurezza che sarebbe garantito dalla presenza di sistemi separati.

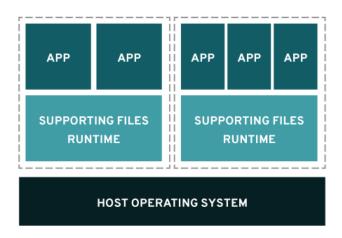


Figura 2.2: Schematizzazione del contenuto di un Container in Docker

Gli strumenti per la creazione di container, come Docker, consentono il deployment a partire da un'*immagine*, ciò semplifica la condivisione di un'applicazione o di un insieme di servizi, con tutte le loro dipendenze, nei vari ambienti. Docker, considera i container come macchine virtuali modulari estremamente leggere, offrendo la flessibilità di creare, distribuire, copiare e spostare i container da un ambiente all'altro, ottimizzando così le app per il cloud.

I contenitori forniscono una modalità standard per impacchettare il codice della tua applicazione, le configurazioni e le dipendenze, in un oggetto singolo e condividono un sistema operativo installato sul server, operando come processi con risorse isolate, assicurando velocità, affidabilità e distribuzioni coerenti, indipendentemente dall'ambiente.

2.3 Strutture dati gerarchiche

Le tabelle di un database relazionale non sono gerarchiche (come nel XML), ma sono delle semplici liste piatte. I dati gerarchici sono constituiti da relazioni padre-figlio che non possono essere rappresentate in modo naturale nelle tabelle di questo tipo. In questo caso, i dati gerarchici sono una collezione di informazioni dove ogni item ha un solo padre e nessuno o più figli (ad eccezione del nodo radice che non ha un nodo padre); questo genere di rappresentazione delle informazioni, simili a un albero, può essere trovato in diversi ambiti di applicazione di un database, incluse discussioni su forum e mailing list, grafici di organizzazione di un business, categorie per gestire contenuti e categorie di prodotti.

Ci sono differenti modelli per poter gestire dati in modo gerarchico, i più importanti presi in considerazione sono i seguenti:

2.3.1 The Adjacency List Model

Il primo approccio, e quello di più semplice implementazione, qui descritto è chiamato Adjacency List Model o metodo ricorsivo; è definito tale perchè il suo funzionamento si basa su una funzione che itera per tutto l'albero.

In questo modello, ogni item (nodo dell'albero) nella tablla contiene un puntatore al suo item padre; invece il nodo radice avrà un puntatore a un valore NULL per l'item padre.

La Tabella 2.1 è un esempio di possibile rappresentazione parziale dei dati nel database implementato in questo progetto secondo questo approccio, seguendo come riferimento la Figura 2.3.

Il vantaggio di usare questo modello sta nella sua semplicità di costruzione, sopratutto a livello di codice client-side, e di restituzione dei figli di un nodo. Mentre diventa problematico se si lavora in puro codice SQL e nella maggior

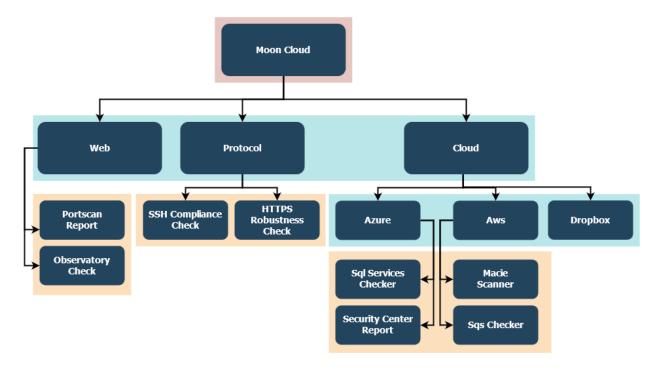


Figura 2.3: Esempio della rappresentazione gerarchica parziale dei dati nel progetto in questione

parte dei linguaggi di programmazione, è lento e poco efficente, perchè è necessaria una query per ogni nodo dell'albero, e visto che ogni query impiega un certo periodo di tempo, questo rende la funzione molto lente quando si lavora con alberi di grandi dimensioni, inoltre molti linguaggi non sono ottimizzati per funzioni ricorsive. Per ogni nodo, la funzione crea una nuova istanza di se stessa e ogni istanza occupa una porzione di memoria e impiega un certo tempo per inizializzarsi, più grande è l'albero e più questo processo sarà portato a termine in maggior tempo.

id	name	parent
1	Moon Cloud	NULL
2	Web	1
3	Protocol	1
4	Cloud	1
5	Portscan Report	2
6	Observatory Check	2
7	SSH Compliance Check	3
8	HTTPS Robustness Check	3
9	Azure	4
10	Aws	4
11	Dropbox	4
12	Sql Services Checker	9
13	Security Center Report	9
14	Macie Scanner	10
15	Sqs Checker	10

Tabella 2.1: Esempio di una possibile tabella per gestire dati in modo gerarchico secondo l'Adjacency List Model

2.3.2 The Nested Set Model

Il secondo approccio analizzato è il *Nested Set Model*, che permette di osservare la gerarchia in un modo diverso, non come nodi e linee (come se fosse un albero), ma come container innestati.

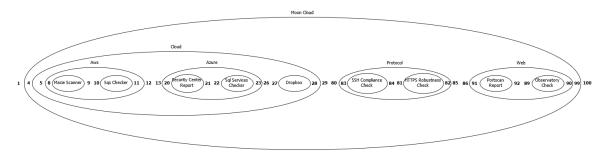


Figura 2.4: Esempio della gestione di dati in modo gerarchico secondo il Nested Set Model, utilizzando dati presi dal database del progetto in questione

Con questo sistema la gerarchia viene mantenuta, secondo il principio cui un nodo padre contiene e suoi figli e questa forma di gerarchia viene mantenuta in tabella attraverso l'uso di due attributi aggiuntivi come è possibile osservare dalla Tabella 2.2 seguente.

id	name	lft	rght
1	Moon Cloud	1	100
2	Web	86	99
3	Protocol	80	85
4	Cloud	4	29
5	Portscan Report	91	92
6	Observatory Check	89	90
7	SSH Compliance Check	83	84
8	HTTPS Robustness Check	81	82
9	Azure	13	26
10	Aws	5	12
11	Dropbox	27	28
12	Sql Services Checker	22	23
13	Security Center Report	20	21
14	Macie Scanner	8	9
15	Sqs Checker	10	11

Tabella 2.2: Esempio di una tabella per gestire dati in modo gerarchico secondo il Nested Set Model

Come è possibile osservare dalla Tabella 2.2 la gerarchia dei dati viene rappresentata attraverso l'uso degli attributi 'left' e 'right' per rappresentare l'annidamento dei nodi (il nome delle colonne: 'left' e 'right', hanno significati speciali in SQL; per questo motivo si identificano questi campi con i nomi 'lft' e 'rght').

L'assegnazione di questi valori ad ogni nodo viene effetuata seguendo questo procedimento: ogni nodo dell'albero viene visitato due volte, assegnando i valori in ordine di visita, e in entrambe le visite. Quindi vengono associati ad ogni nodo due numeri, memorizzati come due attributi. Più precisamente si inizia la visita dell'albero partendo da sinistra e continuando verso destra, un livello alla volta, scendendo per ogni nodo i suoi figli, assegnando i valori al campo left, prima di assegnare un valore al campo right, e successivamente

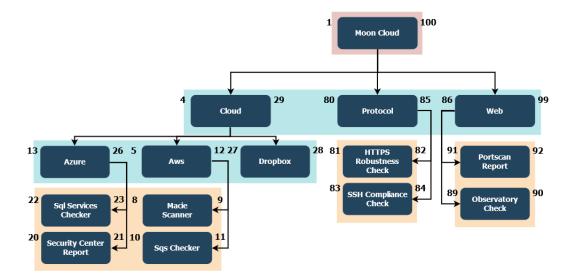


Figura 2.5: Esempio della gestione di dati in modo gerarchico secondo il Nested Set Model, utilizzando dati presi dal database del progetto in questione

si continua verso destra. Questo approccio è chiamato *Modified preorder* tree traversal algorithm (MPTT). A partire da questa tecnica è stato ideata la struttura della tassonomia delle evaluation e dei controlli implementate nella soluzione proposta in questa tesi, con l'ausilio di un package di Python chiamato MPTT.

Più semplicemente se si osserva la parte superiore della Figura 2.4 possiamo notare che la numerazione dei nodi, viene effettuata a partire da container più esterno da sinistra e continua verso destra.

A prima vista questo approccio può sembrare più complicato da comprendere rispetto all'Adjacency List Model, ma quest'utlimo è molto più veloce quando si vuole recuperare i nodi, visto che basta una query, mentre è più lento per operazioni di aggiornamento e cancellazione dei nodi; in quest ultimo il grado di complicatezza dell'operazione è determinato dal nodo che si vuole cancellare, a partire dal caso più semplice, il nodo foglia (un nodo senza figli) fino al caso più complicato, quando si vuole cancellare il nodo radice.

2.4 Sistemi di raccomandazione

Un sistema di raccomandazione (*Recommendation System*) è un sistema che consiglia ad utenti uno o più item esistenti in un database. L'item è un qualsiasi cosa di interesse agli utenti, come prodotti, libri o giornali. Quando si eseguire una raccomandazione si hanno delle aspettative che l'item raccomandato possa essere tra quelli di maggiore interesse; in altre parole, devono essere in accordo con i gusti degli utenti.

Oggigiorno si possono trovare due principali trend di sistemi di raccomandazione:

Content-based filtering (CBF): un item viene raccomandato ad un utente se esso è simile ad altri item di interesse o piaciuti in passato, vengo presi in considerazione prima gli item con alte valutazioni o quelli molto utilizzati. Ogni item ha associate delle informazioni che lo descrivono, questo insieme di dati viene definito metadati, e sono fondamentali per il processo di raccomandazione.

Collaborative filtering (CF): un item viene raccomandato ad un utente se i suoi vicini (altri utenti simili) sono interessati a quello stesso item.

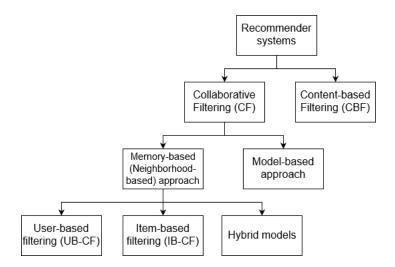


Figura 2.6: Categorizzazione generale dei sistemi di raccomandazione

Entrambi gli approcci (CBF e CF) hanno i loro punti di forza e di debolezza. Il primo algoritmo si focalizza sul contenuto degli item e sugli interessi del singolo utente e propone item differenti a utenti differenti, questo significa che

ogni utente può ricevere raccomandazioni uniche; e questo è un vantaggio. Tuttavia la più grande limitazione del CBF è il fatto di non poter determinare se un utente è interessato ad un item in modo implicito, perchè analizza solamente direttamente i metadati del prodotto e non considera gli interessi di altri utenti, i quali potrebbero suggerire item che non verrebero notati con questo approccio. Per quanto riguarda il CF, nel caso siano presenti molti contenuti e proprietà associati agli item allora il sistema CF consuma molte risorse e tempo per poter analizzarli, nel contempo a questo algoritmo non interessano queste informazioni. Una raccomandazione viene fatta sulla base delle valutazioni degli utenti per gli item, o sugli usi che gli utenti fanno degli item e questo è il suo punto di forza perchè non si trova a dover analizzare item ricchi di informazioni. Allo stesso tempo è anche il suo punto debole, perchè può portare a suggerimenti che potrebbero essere considerati poco adatti sulla base della poca relazione con i profili di alcuni utenti. Questo problema è accentuato quando sono presenti nel database molti item che non hanno valutazioni o non sono stati mai usati dagli utenti [4].

Un sistema di raccomandazione filtra i dati usando differenti algoritmi e raccomanda gli item più rilevanti agli utenti, attraverso un procedimento a 3 fasi:

Raccolta di dati: questo è il primo step e anche quello più importante per poter costruire un sistema di raccomandazione che produca risultanti rilevanti e consistenti. I dati possono essere raccolti in due modi: esplicitamente, cioè attraverso la raccolta diretta di informazioni fornite dagli utenti, ad esempio le valutazioni di un prodotto; mentre attarverso l'approccio implicito, vengono raccolti dati che non sono prodotti in modo intenzionale dall'utente ma ottenuti dai costanti flussi di dati come la cronologia di ricerca, i click effettuati, lo storico degli ordini, etc.

Memorizzazione di dati: la quantità di dati definisce quanto efficace un modello di raccomandazione possa di diventare. Ad esempio, in un sistema di raccomanzione per film, maggiori sono le valutazioni fornite dagli utenti, e migliore sarà il sistema di raccomandazione per gli altri utenti. Il tipo di dati che si vuole raccogliere determina anche il supporto di memorizzazione più adatto.

Filtraggio dei dati : dopo la fase di raccolta e memorizzazione dei dati, essi vanno filtrati per poter estrarre le informazioni rilevanti per poter effettuare le raccomandazioni finali, e sono già disponibili diversi algoritmi che semplificano quest'ultima fase.

I sistemi di raccomandazione possono essere suddivisi nelle seguenti categorie, ma spesso si preferisco degli approcci ibridi, delle combinazioni di sistemi di raccomandazione basati sul Contenuto (Content-based filtering) e di quelli Collaborativi (Collaborative filtering) in modo da essere più efficaci e sfruttare i pregi di entrambi gli approcci.

2.4.1 Content-based filtering

Un Content-based filtering (acronimo CBF) è un sistema di raccomandazione in cui vengono suggeriti, rispetto ad un item (oggetti o prodotti), quelli più simili, il confronto viene effettuato sfruttand i metadati, come il genere, una descrizione, uno o più autori, la categoria di appartenenza, etc.; l'idea base che si trova dietro questi sistemi, si basa sul fatto che se ad un utente piace o interessa un particolare item allora gli piaceranno anche altri con caratteristiche o proprietà simili.

Questo algoritmo suggerisce prodotti che piacevano all'utente nel passato ed è limitato a item dello stesso tipo. Un Content-based recommender fa riferimento a quegli approcci, che provvedono raccomandazioni comparano la rappresentazione del contenuto che descrive un item e la rappresentazione del contenuto dell'item interessato dall'utente.

Questi metodi sono usati quando si conoscono a priori i metadati sugli item che si vuole suggerire, ma nulla sugli utenti. In questo sistema, delle keyword sono utilizzate per caratterizzare gli item e un profilo dell'utente è costruito per memorizzare quali item sono di suo interesse. In altre parole, questi algoritmi cercano di raccomandare quello che l'utente ha valutato positivamente o usato nel passato e sta esaminando nel presente. La costruzione del profilo dell'utente, spesso temporaneo, non viene basata su un modulo di registrazione che l'utente stesso deve compilare, ma su informazioni lasciate indirettamente dall'utente, le quali possono essere: i prodotti che ha maggiormente cercato e acquistato, quelli che sono stati inseriti nella lista dei desideri, etc.. Più precisamente, tra vari item candidati da raccomandare all'utente si passa per un processo di confronto con gli item piaciuti dall'utente e gli item migliori vengono suggeriti.

2.4.2 Collaborative filtering

I Filtri Collaborativi (*Collaborative filtering*, acronimo CF) per poter funzionare come prima cosa costruiscono un database di preferenze degli utenti sulla base di un insieme di item (o prodotti), che a loro volta possono essere presenti un database, sfruttano tecniche di analisi dei dati per risolvere il

problema di aiutare gli utenti a trovare gli item che gli potrebbero piacere producendo, eventualmente una lista dei top-N item da raccomandare per un dato utente. Un utente è sottoposto ad un processo di matching all'interno del database per scoprire quali sono i possibili neighbors, che corrispondono ai possibili utenti aventi storicamente delle preferenze in comune al lui. A questo punto gli item maggiormente preferiti dai neighbors sono raccomandati all'utente visto che potrebbero essere di suo interesse.

Questi sistemi tentano di predire la valutazione o la preferenza che un utente darebbe a un item basandosi su preferenze date da altri utenti, queste ultime possono essere ottenute o in modo esplicito dagli utenti o tramite misurazioni implicite. Inoltre i Filtri Collaborativi non richiedono l'uso di metadati associati agli item come nella loro controparte, i filtri Content-based.

Tuttavia, restano ancora oggi alcune sfide significative a cui sono sottoposti i sistemi di raccomandazione basati su Filtri Collaborativi.

- Il primo obbiettivo è quello di migliorare la scalabilità degli algoritmi di Filtri Collaborativi; questi algoritmi sono in grado di cercare anche diecimila di potenziali neighbors (utenti simili) in tempo reale, ma la richiesta dei sistemi moderni è di cercare dieci milioni di potenziali neighbors, per questo motivo possono nascere problemi di performance con i singoli utenti quando essi hanno molte informazioni.
- Il secondo obbiettivo è quello di migliorare la qualità dei sistemi di raccomandazione per gli utenti. Gli utenti vogliono raccomandazioni di cui possono fidarsi e che possono aiutarli a trovare item che potrebbero essere di loro gusto.

Per certi versi questi due obbiettivi sono in conflitto tra di loro e per ottenere dei risultati validi e di una certa importanza è necessario trattarli in contemporanea perchè aumentare solamente la scalabilità diminuirebbe la sua qualità e viceversa [8].

Il principale modello di Filtri Collaborativi studiato in questo elaborato e approfondito nel capitolo successivo, è il metodo definito come *Memory-based* e il vantaggio di utilizzare queste tecniche sta nel fatto di essere semplici da implementare e i risultati ottenuti sono altrettanto semplici da interpretare; mentre ci possono essere anche Filtri Collaborativi che sfruttano metodi *Model-based* che si basano sulla fattorizzazione di matrici e sono molto più funzionali per gestire il problema della parsità dei dati. Questi ultimi sono sviluppati usando algoritmi di data mining e machine learning per predire

le valutazioni di utenti su item senza valutazioni, tentando di comprimere grandi database in un modello ed effettuare il processo di raccomandazione applicando dei meccanismi di riferimento all'interno di questo modello. I CF Model-based possono rispondere alle richieste degli utenti istantaneamente [4].

2.4.3 Cold Start problem

Cosa succederebbe se un nuovo utente o un nuovo item venisse aggiunto al database? Questa situazione è chiamata *Cold Start*. Ci possono essere due tipi di Cold Start:

Visitor Cold Start: si verifica quando un nuovo utente è stato aggiunto al database, visto che non c'è alcuno storico relativo ad esso, il sistema non sa le sue preferenze; per questo motivo diventa molto più difficile raccomandare prodotti a quel particolare utente. Per risolvere questo problema, a livello teorico, si potrebbe applicare un procedimento di raccomandazione basata sulla popolarità dei prodotti, ma solo una volta che si è venuti a conoscenza delle preferenze dell'utente, sarà possibile generare delle raccomandazioni più precise e adeguate alle sue esigenze.

Item Cold Start: si verifica quando un nuovo item viene inserito nel sistema. L'azione dell'utente è quella più importante per determinare il valore di questo item; maggiore l'interazione un item riceve, più è facile che venga raccomandato all'utente giusto.

Capitolo 3

Collaborative filtering

In questo capitolo verranno approfonditi gli algoritmi di raccomandazione implementati nella soluzione, mostrando le porzioni di codice e spiegando i vari passagi che portano ad ottenere delle raccomandazioni.

3.1 Memory-based

I Filtri Collaborativi Memory-based sono stati introdotti per via delle osservazioni che vennero fatte dalla comunità, dicenddo che gli utenti si fidano maggiormente delle raccomandazioni di altri che la pensano allo stesso modo. Questi metodi mirano a calcolare le relazioni tra utenti e item attraverso lo schema dei vicini che identifica sia coppie di item che tendono ad essere usati insieme o hanno un grado di similarità alto o utenti con uno storico di item usati simile. [6] Questi approcci divennero molto famosi grazie alla loro semplicità di implementazione, molto intuitivi, non necessitano di operazioni di training sui dati e regolazione di molti parametri, inoltre l'utente può capire la ragione che sta dietro ogni raccomandazione.

Questa categoria di sistemi di raccomandazione sono definiti anche Neighborhood-based e possono essere ulteriormente classificati in due sottocategorie:

3.1.1 User-based filtering

Questo sistema, definiti anche con l'acronimo UB-CF (*User-based Collabora-tive Filter*) basa tutto il suo funzionamento sulla comunità di utenti, maggiore è la sua dimensione e l'attività degli utenti con item o servizi e migliori potranno essere le raccomandazioni. Questo algoritmo fornisce dei suggeri-

menti ad un utente sulla base di uno o più vicini, e la similarità tra utenti può essere determinata sulla base degli item che l'utente ha utilizzato o valutato.

Molti di questi approcci possono essere generalizzati dall'algoritmo organizzato nei seguenti passi:

- 1. Specificare qual'è l'utente a cui si vuole applicare l'algoritmo di raccomandazione e recuperare quali utenti possono avere dato valutazioni o usato item simili al utente target. Piuttosto che recuperare tutti gli utenti, per velocizzare l'esecuzione dell'algoritmo, è possibile selezionare soltanto un gruppo di utenti in modo casuale oppure associare dei valori di similarità tra tutti gli utenti e confrontando questi valori con quello dell'utente target, selezionare i relativi utenti che superano una soglia scelta, oppure utilizzare tecniche di clustering.
- 2. Estrarre quegli item a cui l'utente target non ha mai interagito e per questo motivo gli possono interessare, e mostrarli sottoforma di raccomandazioni.




Figura 3.1: Esempio di applicazione di un sistema di raccomandazione Userbased

Questi approcci sono facilmente implementabili, indipendenti dal contesto in cui sono applicati e possono essere più accurati rispetto a tecniche basate sul Content-based filtering; dall'altra parte all'aumentare del numero di utenti che vado a considerare per fare le raccomandazioni migliore è la precisione di questo processo ma anche è maggiore il costo in termini di tempo.

Nella soluzione proposta in questa tesi, l'algoritmo UB-CF viene implentato come funzione che prende in ingresso un parametro (user_other_id),

come è possibile osservare da 3.1.1 corrispondente all'identificativo per l'utente, e restituisce una lista di raccomandazioni (similar_user_evaluations) corrispondenti alle Evaluation simili a quelle usate da altri utenti.

```
1 # User recommendation algortihm 2 def user_recommendation_alg(user_other_id):
```

Più precisamente il funzionamento dell'algoritmo si svolge seguendo i seguenti passi:

• il primo passo è quello di recuperare sulla base del parametro in ingresso alla funzione, lo user_other_id, tutte le Evaluation che l'utente in questione ha utilizzato;

```
# Select the target user and its evaluations
target_user_evaluations = User.objects.get(other_id=user_other_id).evaluations.all()\
.values('other_id', 'id', 'parent_id')\
.order_by('other_id')
```

• il secondo passo consiste nel selezionare le Evaluation usate dagli altri utenti, e viene create una lista di queste Evaluation;

• il terzo passo consiste nell'andare a determinare quali tra le Evaluation dell'utente a cui si vuole raccomandare quali sono quelle simili usate dagli altri utenti. Per determinare le Evaluation simili si è andato a confrontare il paramentro parent_id (identifica all'interno della tassonomia quale sia il nodo padre per quella Evaluation), associato ad ogni Evaluation, in questo modo si è andati a selezionare soltanto gli item appartenenti a una stessa categoria, eliminando eventuali nodi duplicati. E componendo una lista finale con le Evaluation restanti.

```
not (o_users_evaluation in similar_user_evaluations)): # the 'similar_user_evaluations' list
similar_user_evaluations.append(o_users_evaluation)
```

Nel capitolo successivo verrano mostrati degli esempio pratici in cui è stato applicato questo algoritmo.

3.1.2 Item-based filtering

Quando viene applicato per milioni di utenti e item, l'algoritmo UB-CF non è molto efficente, per via della complessa computazione della ricerca di utenti simili; così in alternativa è stato introdotto l'algoritmo di filtraggio Itembased, definito anche IB-CF (*Item-based Collaborative Filter*) dove piuttosto che effetuare il confronto tra utenti simili, viene fatto un confronto tra gli item dell'utente a cui si vuole raccomandare e i possibili item simili.

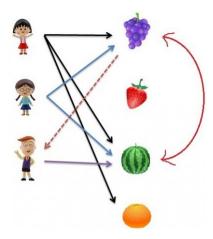


Figura 3.2: Esempio di applicazione di un sistema di raccomandazione IB-CF.

Questi sistemi sono estremamente simili ai sistemi di raccomandazione Contentbased, e identificano item simili in base a come utenti gli hanno usati nel passato [8].

A livello pratico nella soluzione proposta, questo algoritmo è stato implementato come funzione che prende in ingresso un parametro item_other_id rappresentante l'other_id, un attributo associato ad ogni nodo della tassonomia che lo identifica, del item su cui si vuole ottenere altri item simili; in generale per determinare la similarità tra due oggetti, si osserva l'attributo parent_id associato ad ogni item, che determina quale sia il nodo padre all'interno della tassonomia, quindi alla fine vengono selezionati quegli item che appartengono alla stessa categoria.

In generale CF-IB ideato per determinare Evaluation simili funziona seguendo i seguenti passi:

• il primo passo è quello di recuperare sulla base del parametro in ingresso alla funzione, lo item_other_id, l'Evaluation su cui si vuole determinare le altre Evaluation simili;

```
def item_recommendation_alg(item_other_id):

# Selecting the evaluation, which is applied this algorithm, from its other_id

# SELECT * FROM recommendation_app_evaluation WHERE other_id = %(item_other_id)s AND
node_type = 'eva'

target_eval = Evaluation.objects.filter(Q(other_id=item_other_id) & Q(node_type="eva"))\

. values('other_id', 'id', 'parent_id')[0]
```

• il secondo passo è quello di recuperare tutte le Evaluation, escludendo la prima recuperata, presenti nella base di dati;

```
# Selecting the other evaluations, excluding the target evaluation

# SELECT * FROM recommendation_app_evaluation WHERE other_id != %(item_other_id)s AND

node_type = 'eva'

all_other_evals = Evaluation.objects.filter(~Q(other_id=item_other_id) & Q(node_type="eva"

)) \

.values('other_id', 'id', 'parent_id').order_by('other_id')
```

• il terzo ed ultimo passo consiste nel andare a determinare le Evaluation che hanno lo stesso parent_id, quindi quelle appartenenti alla stessa categoria, dell'Evaluation ottenuta nel primo passo; inoltre, se presenti, vengono eliminati eventuali duplicati;

```
# Creating a list with all the evaluations that are similar to the target evaluation (
    comparing the parent_id)
similar_item_evaluations = []
for evaluation in all_other_evals:
    # Taking only the evaluations that have: different other_id (excluding the target
    evaluation

# in the recommendation) and same parent_id and the evaluations that weren't added to
    similar_item_evaluations
# list

if ((target_eval['other_id'] != evaluation['other_id']) and # Evaluations must have
    different 'other_id'

(target_eval['parent_id'] == evaluation['parent_id']) and # Evaluations must have
    same 'parent_id')
# Evaluation in all_other_evals list mustn't be already added to \
    not (evaluation in similar_item_evaluations)): # the 'similar_item_evaluations' list
    similar_item_evaluations.append(evaluation)

return similar_item_evaluations
```

Altro algoritmo del tipo IB-CF implementato in questa tesi sulla falsa riga di quello appena riportato qua sopra, è quello ideato per determinare quali Evaluation possono essere raccomandate per un Target inserito da un utente tra quelli supportati da Moon Cloud, che sono: Host avente Windows come sistema operativo, Host avente Linux come sistema operativo, sistemi che sfruttano servizi di Aws o di Azure e Url di siti web.

In Python questo algoritmo viene implementato come funzione che prende in ingresso l'id (identificativo univoco) del Target, e restituisce l'insieme delle Evaluation raccomandate per quel Target, il tutto viene eseguito seguendo questi passi:

• il primo passo è quello di recuperare tutte le Evaluation presenti nel database:

```
def target_recommendation_alg(target_id):
    # Retriving all the evaluations in the database
    evaluations = Evaluation.objects.filter(node_type="eva")
4
```

• il secondo ed ultimo passo è quello di andare a determinare quali sono i Controlli che hanno lo stesso target_type_id del Target id passato come parametro della funzione, e da quei Controlli determinare le Evaluation che li utilizzano, eliminando eventuali duplicati; determinando così le possibili Evaluation applicabili per quel Target.

```
# Saving in the target_evaluations list the evaluations which controls have target_type_id equal to target_id
target_evaluations = []
for evaluation in evaluations: # Scanning all the evaluations
for evaluation_controls in evaluation.controls.filter(target_type_id=target_id):
    if not(evaluation in target_evaluations): # Excluding evaluations duplicated
    target_evaluations.append(evaluation)

# Converting the Evaluation model's instance in a dict and putting the evaluation, as a dict, in a list
target_evaluations_serializer = EvaluationSerializer(target_evaluations, many=True)

return target_evaluations_serializer.data
```

Nel capitolo successivo verrano mostrati anche degli esempi dei valori di risposta di queste funzioni.

3.1.3 Hybrid filtering

Nei sistemi di raccomandazione ibridi si tende a voler combinare più tecniche di raccomandazione, cercando di raggruppare i pregi di ciascuna tecnica; infatti se uno compara i sistemi di raccomandazione ibridi con i sistemi Collaborativi o Content-based, la precisione dei suggerimenti è solitamente maggiore.

Nella soluzione proposta in questa tesi, questo algoritmo viene direttamente implementato come Api Rest, alla quale viene passato come parametri la request, l'oggetto HTTP che il browser invia al server contenente la richiesta HTTP attraverso un certo URL e lo user_other_id è un valore che viene preso dall'URL, e rappresenta l'other_id dell'utente su cui si andrà a raccomandare. Inoltre il tutto viene limitato ad essere richiamato solo tramite richieste HTTP con metodo GET.

Nel codice 3.1 possiamo vedere come vengono limitate le richieste al metodo GET e come viene definita la funzione.

```
1 @api_view(['GET'])
2 def hybrid_recommendation(request, user_other_id)
```

Listing 3.1:

Il funzionamento di questo algoritmo si svolge nei seguenti passi:

• il primo passo è quello di verificare se l'utente esiste nel database altrimenti viene generata un eccezione (errore) che viene gestito in modo personalizzato, generando una risposta HTTP con codice di errore 404 (Not Found);

```
# Trying to retrive the actual User with user_other_id
user = User.objects.get(other_id=user_other_id)
3
```

• il secondo passo è applicare l'algoritmo di User Recommandation, descritto nella sezione precendete, per le Evaluation e ottenere due liste, la prima target_user_evaluations contiene le Evaluation che l'utente ha utilizzato, mentre nella seconda similar_user_evaluations si avranno le Evaluation che gli altri utenti hanno utilizzato e che sono simili alle Evaluation del primo utente;

• il terzo passo consiste nell'applicazione dell'algoritmo Item-based per ogni Evaluation usata dall'utente in questione così da ottenere delle raccomandazioni che sono compatibili con le Evaluation usate dall'Utente; la similarità o appartenenza alla stessa categoria viene ottenuta osservando il valore del parent_id; anche in questo caso vengono eliminati eventuali duplicati e viene formata una lista similar_item_evaluations contenente le Evaluation simili ottenute dall'applicazione dell'algoritmo di raccomandazione Item-based;

```
# For every evaluation used by users is extracted all other possible evaluations that have
                    'parent_id
        similar_item_evaluations = []
        for t_user_evaluation in target_user_evaluations: # for every target user's evaluatio
for item_evaluation in item_recommendation_alg(t_user_evaluation['other_id']): # is
         applied the item_recommendation algorithm
# Taking only the evaluations that have: different other_id (excluding the target
            # in the recommendation) and same parent_id and the evaluations that weren't added to
               lar_item_evaluations
            # list or to 'similar_user_evaluations' or to 'target_user_evaluations
               ((t_user_evaluation['other_id'] != item_evaluation['other_id']) and # Evaluations
                 must have the same 'parent_id'
# Evaluation in all_other_evals list mustn't be already added to \
         not (item_evaluation in similar_item_evaluations) and \mbox{\tt\#} the similar_item_evaluations' list,
12
                  not (item_evaluation in similar_user_evaluations) and # the '
_user_evaluations' list or
                 not (item_evaluation in target_user_evaluations)): # the 'target_user_evaluations'
               similar_item_evaluations.append(item_evaluation)
```

• il quarto passo consiste nel raggruppare le due liste contenenti le Evaluation raccomandate per l'utente secondo l'applicazione dei due algoritmi, eliminando anche eventuali duplicati, così da ottenere un'u-

nica lista similar_evaluations la quale viene ritornata dalla funzione sottoforma di risposta HTTP in formato Json;

```
# Putting together the evaluations recommended in similar_user_evaluations list and similar_item_evaluations list
similar_evaluations = []

# Adding to similar_evaluations list the evaluation in the similar_user_evaluations list
for s_user_evaluation in similar_user_evaluations:
similar_evaluations.append(s_user_evaluation)

# Adding to similar_evaluations list the evaluation in the similar_item_evaluations list
for item_evaluation in similar_item_evaluations:

# Taking only the evaluations that weren't added to \
if (not (item_evaluation in similar_evaluations) and # the 'similar_evaluations' list or
not (item_evaluation in target_user_evaluations)): # the 'target_user_evaluations'
list
similar_evaluations.append(item_evaluation)
similar_evaluations = sorted(similar_evaluations, key=lambda i: i['other_id'])

return JsonResponse(similar_evaluations, safe=False)
```

Nel capitolo successivo verrà mostrato un esempio di risposta quando viene chiamata questa funzione, e verrà approfondito il contesto che è stato costruito attorno agli algoritmi di raccomandazione descritti in questo capitolo.

Capitolo 4

Descrizione della soluzione

In questo capitolo verrà approfondito l'aspetto puramente pratico e le fasi che hanno portato alla realizzazione della soluzione; inoltre verranno mostrate le applicazioni pratiche degli aspetti teorici enunciati nei capitoli precedenti, unitamente alle difficoltà principali incontrate.

Prima di poter costruire il sistema di raccomandandazione proposto in questa tesi, sono state eseguite delle operazioni preliminari per poter impostare il progetto di Django e la relativa applicazione che implementerà effettivamente la soluzione.

Come annunciato nei capitoli precendenti per procedere alla costruzione di un sistema di raccomandazione bisogna avere a disposizione una base di dati solida da cui attingere tutte le informazioni; ed è proprio questo il primo passo che è stato seguito, disegnare e progettare una base di dati da cui partire per la realizzazione degli algoritmi proposti. In generale Moon Cloud possiede una struttura delle Evaluation ad albero, quindi anche di conseguenza anche le tabelle del database rispecchiano questa struttura, sulla base delle considerazioni sulle tecniche adottate sono state fatte nei capitoli precendenti.

Per implementare un modified pre-order trasversal tree in Django, si è fatto uso del package MPTT, come detto in precendenza, questa tecnica è usata per memorizzare dati gerarchici in un database, puntando all'efficenza nelle operazioni di recupero dei dati e scendendo a compromessi per quanto riguarda le operazioni di inserimento e spostamento dei nodi all'interno della struttura. Grazie all'usilio di questa utility la costruzione dei Model del progetto sono stati semplificati e qui di seguito 4 è possibile trovare le porzioni principali del codice costituente i Model, i quali poi vengono utilizzati da

Diango per la generazione della base di dati.

```
# Target supported by Moon Cloud
        Lass TargetType(models.Model):
TYPES = (
            PES = (
('host', 'host'),
            ('windows', 'windows'),
('url', 'url'),
('azure', 'azure'),
        name = models.CharField(max_length=150, choices=TYPES, default="host")
descr = models.TextField(max_length=1000, default="none")  # Descripti
10
     # Control that can be part of evaluations
class Control(MPTTModel):
        other_id = models.IntegerField(default=-1, unique=True)
parent = TreeForeignKey('self', on_delete=models.CASCADE, null=True, blank=True, related_name='
             children')
       children')
name = models.CharField(max_length=150, unique=True)
descr = models.TextField(max_length=1000, default="none")  # Description of a node in the taxonomy
TYPES = (
   ('cat', 'category'),
   ('con', 'control')
        # Possible node type of the taxonomy (category node or control node)
node_type = models.CharField(max_length=3, choices=TYPES, default='cat')
target_type = models.ForeignKey(TargetType, null=True, blank=True, on_delete=models.CASCADE) # It'
              s null for the root node and category nodes
27
28
     # Evaluation used by users (group of controls)
class Evaluation(MPTTModel):
        other_id = models.IntegerField(default=-1, unique=True)
parent = TreeForeignKey('self', on_delete=models.CASCADE, null=True, blank=True, related_name='
             children')
        cnitaren')
name = models.CharField(max_length=150, unique=True)
descr = models.TextField(max_length=1000, default="none")  # Description of a node in the taxonomy
TYPES = (
   ('cat', 'category'),
   ('eva', 'evaluation')
33
        # Possible node types of the taxonomy (category node or evaluation node)
node_type = models.CharField(max_length=3, choices=TYPES, default='cat')
controls = models.ManyToManyField(Control) # Evaluation can be composed of one or more controls
40
     # Users with a Moon Cloud account who can use evaluations
     class User (models.Model):
        other_id = models.IntegerField(default=-1, unique=True)
email = models.EmailField(max_length=50, unique=True)
46
        evaluations = models.ManyToManyField(Evaluation, blank=True)  # Evaluations chosen by user
48
50
     # Target table to save the targets type (more than one) that a user can have
               Target (models.Model):
                 = models.ForeignKey(User, blank=True, on_delete=models.CASCADE)  # User has chosen some
     target_type
other_id = models.IntegerField(default=-1, unique=True)
target_type = models.ForeignKey(TargetType, blank=True, on_delete=models.CASCADE) # TargetType Id
```

Listing 4.1: Parti principali del codice dei Models della soluzione

A partire da questo Model vennero introdotte nel database le seguenti tabelle, le quali è possibile visionare nella Figura 4.1:

Control: contiene l'insieme dei software che vengono poi effetivamente eseguiti all'interno di una Evaluation, i campi other_id (identificativo che fa riferimento al database effetivo di Moon Cloud), descr (una descrizione del funzionamento del controllo), node_type (definisce se il nodo è un Evaluation o un nodo Categoria) definiscono le caratteristiche del controllo mentre lft, rght, tree_id, level e parent sono introdotti automaticamente dal package MPTT per poter rappresentare i dati in

- modo gerarchico, infine target_type_id rappresenta, quel controllo a quale Target viene associato.
- **Evaluation**: contiene l'insieme di Evaluation che un utente può eseguire per un certo Target, e allo stesso modo i campi contenuti nella tabella Control. La tabella intermedia evaluation_controls permette di memorizzare quali controlli sono associati a quali Evaluation.
- User : contiene gli utenti registrati alla piattaforma Moon Cloud, e sono anche loro, come con le tabelle precedenti, identificati con un campo other_id, e distinti da un email. La tabella intermedia user_evaluations permette di memorizzare quali Evaluation un utente ha selezionato e usato.
- **Target** : è utilizzata per memorizzare quali Target un utente ha inserito e sui quali vuole effettuare dei processi di Evaluation.
- **TargetType**: specifica quali sono i tipi di Target supportati da Moon Cloud.

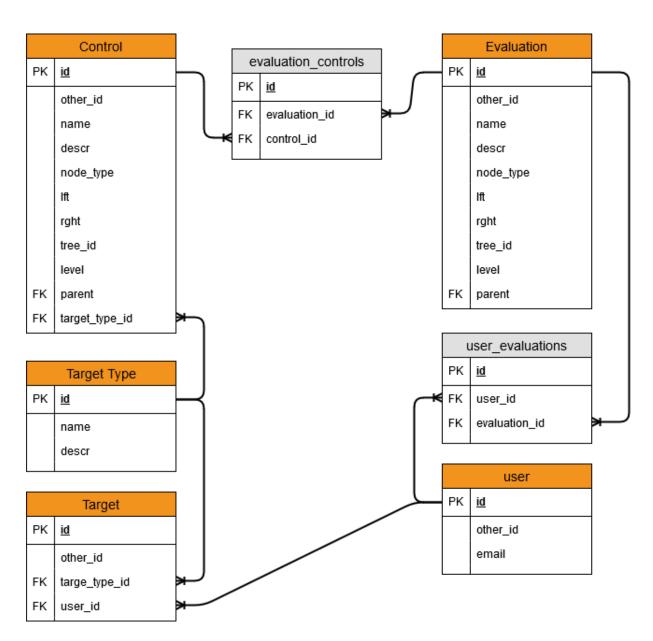


Figura 4.1: Struttura del database

Successivamente per poter testare che la tassonomia creata per le Evalution e i Controlli fosse corretta e funzionante si è implementata un'interfaccia Web a scopo didattico. Avviando il server, la home page che viene prooposta è mostrata nella Figura 4.2, dalla quale è possibile accedere alle pagine specifiche per la navigazione della tassonomia delle Evaluation piuttosto che dei Controlli; inoltre tramite la barra di navigazione è possibile tornare a questa home page o accedere alla admin page generata da Django, e succesivamente personalizzata, per poter manipolare la base di dati.

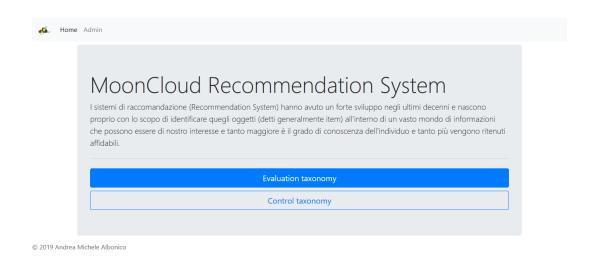


Figura 4.2: Home page

```
1 # Index page where you can choose to navigate the evaluation taxonomy or the control taxonomy
2 def index(request):
3 return render(request, "recommendation_app/index.html")
```

Listing 4.2: Parte principale del codice delle View della soluzione per gestire l'accesso alla home page

Una volta scelta la tassonomia su cui si vuole navigare, è possibile, per ogni singolo nodo, recuperare: i discendenti, la famiglia, i fratelli, e gli antenati; ed è anche possibile scaricare un file scritto in linguaggio DOT e un'immagine in formato png rappresentante la gerarchia dei dati contenuti nella base dati. Inoltre è possibile osservare in maniera più approfondita le informazioni rilevanti sulla tassonomia contenute nelle tabelle del database.

₩. Н	lome Admin		
	Operations you can daxonomy Select an Evaluation:	do on evaluation's	Complete evaluation's taxonomy
	Select an Operation: Children		Show details of the Taxonomy
	search		moon cloud o backup
	Request a dot schema and a png file		o cloud ■ aws ■ inspector vulnerability scan ■ macie scanner ■ sqs checker
	You can add, delete or move a node All evaluation's categories - moon cloud - backup - cloud - aws - azure - dropbox	All evaluations - inspector vulnerability scan - macie scanner - sqs checker - logging and monitoring check - networking checker - other security considerations	aure logging and monitoring check networking checker other security considerations checker security center report sql services checker storage account check dropbox custom database

Figura 4.3: Home page per la navigazione della tassonomia

1 1 moon cloud root node cat 1 100 1 0 None 16 16 backup none cat 2 3 1 1 1 4 4 cloud none cat 4 29 1 1 1 5 5 aws none cat 5 12 1 2 4 36 36 inspector vulnerability scan AWS Inspector. eva 6 7 1 3 5 Recommend for 3 34 34 macie scanner Macie Scanner. eva 8 9 1 3 5 Recommend for 3	Taxonomy details										
16 16 backup none cat 2 3 1 1 1 4 4 cloud none cat 4 29 1 1 1 5 5 aws none cat 5 12 1 2 4 36 36 inspector vulnerability scan AWS Inspector. eva 6 7 1 3 5 Recommend for 3 34 34 macie scanner Macie Scanner: eva 8 9 1 3 5 Recommend for 3	Id		Name	Description		Left	Right		Level		Recommendation
4 4 cloud none cat 4 29 1 1 1 5 5 aws none cat 5 12 1 2 4 36 36 inspector vulnerability scan AWS Inspector. eva 6 7 1 3 5 Recommend for 3 34 34 macie scanner Macie Scanner. eva 8 9 1 3 5 Recommend for 3	1	1	moon cloud	root node	cat	1	100	1	0	None	
5 5 aws none cat 5 12 1 2 4 36 36 inspector vulnerability scan AWS Inspector. eva 6 7 1 3 5 Recommend for 3 34 34 macie scanner Macie Scanner. eva 8 9 1 3 5 Recommend for 3	16	16	backup	none	cat	2	3	1	1	1	
36 36 inspector AWS Inspector. eva 6 7 1 3 5 Recommend for 3 34 34 macie scanner Macie Scanner. eva 8 9 1 3 5 Recommend for 3	4	4	cloud	none	cat	4	29	1	1	1	
vulnerability scan 34 34 macie scanner Macie Scanner. eva 8 9 1 3 5 Recommend for 3	5	5	aws	none	cat	5	12	1	2	4	
	36	36		AWS Inspector.	eva	6	7	1	3	5	Recommend for 36
35 35 sqs checker AWS Sqs. eva 10 11 1 3 5 Recommend for 3	34	34	macie scanner	Macie Scanner.	eva	8	9	1	3	5	Recommend for 34
	35	35	sqs checker	AWS Sqs.	eva	10	11	1	3	5	Recommend for 35

Figura 4.4: Dettagli della tassonomia sottoforma di tabella come nella base di dati

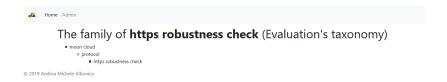


Figura 4.5: Risultato dell'operazione selezionata sul nodo in questione

Qui di seguito 4 è possibile trovare il codice scritto all'interno delle View per poter eseguire tutte le operazioni descritte sopra.

```
# The home page shows all taxonomy and a form to make operations on it
def tax_index(request, parameter):
    # If this is a POST request we need to process the form data
    if request.method == 'POST':
          # Create a form instance and populate it with data from depending on the parameter
if (parameter == "evaluation"):
            form = EvaluationOperationForm(request.POST)
10
             form = ControlEvaluationForm(request.POST)
11
12
          if form.is_valid():
            # Process the data in form.cleaned_data as required
nodename_form = form.cleaned_data['nodeName']
taxonomy_operation_form = form.cleaned_data['actionTax']
13
           # Redirect to a new URL (page that show a part of the taxonomy, depending on the action user has chosen):
16
17
            return redirect(
   reverse('rec:tax_index', args=[parameter]) + str(nodename_form) + '_' +
       taxonomy_operation_form)
# If id's a GET method we'll create a blank form
19
20
\frac{21}{22}
               (parameter == "evaluation"):
            form = EvaluationOperationForm()
23
            form = ControlEvaluationForm()
      # Depending on the parameter, I'm getting all the categories of Evaluations or Controls taxonomy
      " pepending on the parameter, I'm getting all the categorie
and save it in a
# list called "categories_list"
if (parameter == "evaluation"):
    q_categories = Evaluation.objects.filter(node_type='cat')
else:
26
27
29
30
      q_categories = Control.objects.filter(node_type='cat')
categories_list = []
for node in q_categories:
   categories_list.append(node.name)
31
32
33
35
36
      # Depending on the parameter, I'm getting all the categories of Evaluations or Controls node in the
              taxonomy
       # and save it in a list called "node_list"
if (parameter == "evaluation"):
37
39
       q_nodes = Evaluation.objects.filter(node_type='eva')
else:
40
       q_nodes = Control.objects.filter(node_type='con')
node_list = []
41
42
       for node in q_nodes:
   node_list.append(node.name)
43
45
       # Depending on the parameter, I'm getting all the Evaluations or Controls taxonomy
if (parameter == "evaluation"):
   tax = Evaluation.objects.all()
47
49
          tax = Control.objects.all()
51
       # Passing the complete taxonomy and data to fill the form so you can operate on the taxonomy
args = {'tax': tax,
   'categories': categories_list,
52
53
            'nodes': node_list,
'form': form,
'request_path': parameter}
55
57
      return render(request, "recommendation_app/tax_index.html", args)
59
60
61
62 # Show the taxonomy's details page showing an overview of the taxonomy
    def tax_details(request, parameter):
   if (parameter == 'evaluation'):
     tax_details_obj = Evaluation.objects.all()
63
64
65
66
67
          tax_details_obj = Control.objects.all()
68
      69
70
74\, # Create the .dot file (based on the Dot language) and the graph showing the taxonomy in .png format
75 def dot_graph(request, parameter):
76 # Create a graph object
```

```
taxonomy_dot_object = Graph(comment='Taxonomy', format='png')
# Fill the graph with every node in the database (evaluations/controls node and categories nodes),
# and create a link with the parent node
if (parameter == 'evaluation'):
 79
 81
           taxonomy_nodes = Evaluation.objects.all()
        taxonomy_nodes = Control.objects.all()
i = 0
 83
        for node in taxonomy_nodes.order_by('level'):
    # This If construct will prevent the adding of an empty node to the root node in the graph
 85
         if (i == 0):
 87
 89
             taxonomy_dot_object.node(str(node.id), label=str(node.name))
 91
             # Insert the other nodes
             taxonomy_dot_object.node(str(node.id), label=str(node.name))
 93
             taxonomy_dot_object.edge(str(node.parent_id), str(node.id))
        # Specify where I want to save the .png image and the .dot file taxonomy_dot_object.render('taxonomy_output/taxonomy.dot')
 95
        # This function is used to zip a directory
        # Inis runction is used to zip a director;
def make_zipdir(path, ziph):
    # Ziph is zipfile handle
    for root, dirs, files in os.walk(path):
        for file in files:
 99
100
101
                ziph.write(os.path.join(root.file))
104
       # Making the zip file
zip_file = zipfile.ZipFile('taxonomy_output.zip', 'w', compression=zipfile.ZIP_DEFLATED)
make_zipdir('taxonomy_output/', zip_file)
106
107
108
        zip_file.close()
109
110
111
       # Remove the directory which was zipped and all files inside
shutil.rmtree("taxonomy_output/")
112
       return redirect (reverse ('rec:index'))
114
     # Method to navigate the taxonomy
116
119 # Based on the MPTT's method 'get descendants' that return the descendants of a model instance, in
             tree order
def show_descendants(request, nodename, parameter):
      if (parameter == 'evaluation'):
121
        q_result = Evaluation.objects.get(name=nodename).get_descendants(include_self=False)
# Get the count of descendants of the model instance
        q_result_num = Evaluation.objects.get(name=nodename).get_descendant_count() else:
126
         q_result = Control.objects.get(name=nodename).get_descendants(include_self=False)
         # Get the count of descendants of the model instance
q_result_num = Control.objects.get(name=nodename).get_descendant_count()
130
       return render(request, "recommendation_app/tax_node_details.html",
                  'tender(request, recommendation_app.can_node,
('tax_type': (str(parameter)).capitalize(),
'descendants': q_result,
'node_exe': nodename,
'method': 'descendants',
131
134
                   'num_descendants': q_result_num})
136
138 # Based on the MPTT's method 'get children' that return the immediate children of a model instance,
139
     def show_children(request, nodename, parameter):
      q_result = Evaluation.objects.get(name=nodename).get_children()
else:
140
141
142
143
          q_result = Control.objects.get(name=nodename).get_children()
145
       return render(request, "recommendation_app/tax_node_details.html",
                   'enter(lequest, recommendation_app,cax_mode,
''tax_type': (str(parameter)).capitalize(),
'children': q_result,
'node_exe': nodename,
146
149
                  'method': 'children'})
151
152 # Based on the MPTT's method 'get family' that return the ancestors, the model instance itself and
            the descendants,
153 # in tree order
154~\mbox{def} show_family(request, nodename, parameter):
     if (parameter == 'evaluation'):
    q_result = Evaluation.objects.get(name=nodename).get_family()
```



Figura 4.6: Admin page

Listing 4.3: Parti principali del codice delle View della soluzione per gestire la navigazione delle tassonomie, quella delle Evaluation e quella dei Controlli

Per poter agilmente manipolare la base di dati, Django mette a disposizione la cosidetta Admin Page mostrata in Figura 4.6, che è stata personalizzata per mostrare le tabelle su cui è possibile effetuare modifiche, e per ognuna vengono mostrate le informazioni più rilevanti, come mostrato dalla Figura 4.7 nel caso della tabella Evaluation, e dalla quale è possibile effetuare ricerche, eliminare direttamente i dati contenuti nel database e aggiungere nuovi dati, come mostrato in Figura 4.8.

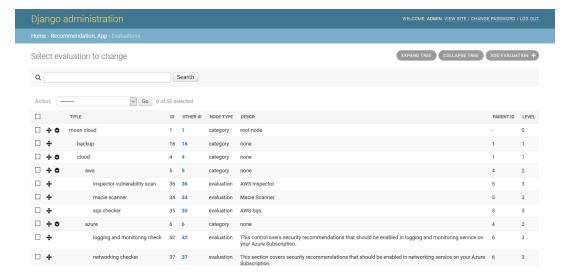


Figura 4.7: Esempio di Admin page per le Evaluation

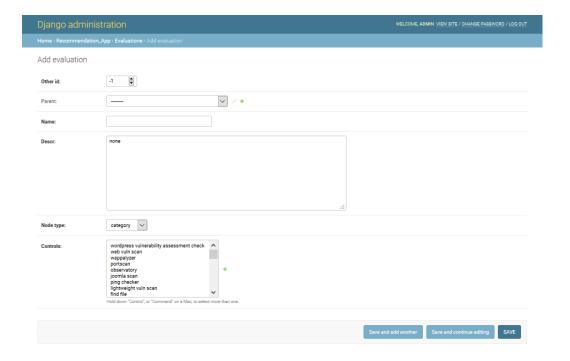


Figura 4.8: Esempio di Admin page per il caso in cui si vuole aggiungere una nuova Evaluation

Capitolo 5

Conclusioni

Bibliografia

- [1] M. Anisetti et al. «A semi-automatic and trustworthy scheme for continuous cloud service certification». In: *IEEE TRANSACTIONS ON SERVICES COMPUTING* (2017). DOI: 10.1109/TSC.2017.2657505.
- [2] M. Anisetti et al. «Moon Cloud: A Cloud Platform for ICT Security Governance». In: (dic. 2018), pp. 1–7. DOI: 10.1109/GLOCOM.2018.8647247.
- [3] Django documentation. https://docs.djangoproject.com/en/2.2/. 2019.
- [4] Minh-Phung Do, Dung Nguyen e Academic Network of Loc Nguyen. «Model-based approach for Collaborative Filtering». In: ago. 2010.
- [5] MDN Django documentation. https://developer.mozilla.org/it/docs/Learn/Server-side/Django/. 2019.
- [6] Miquel Montaner, Beatriz López e Josep Lluís de la Rosa. «A Taxonomy of Recommender Agents on the Internet». In: Artificial Intelligence Review 19.4 (giu. 2003), pp. 285–330. ISSN: 1573-7462. DOI: 10.1023/A: 1022850703159. URL: https://doi.org/10.1023/A:1022850703159.
- [7] Python 3.7 documentation. https://docs.python.org/3.7/. 2019.
- [8] Badrul Sarwar et al. «Item-based Collaborative Filtering Recommendation Algorithms». In: WWW '01 (2001), pp. 285-295. DOI: 10.1145/371920.372071. URL: http://doi.acm.org/10.1145/371920.372071.